Codex 任务书：兄弟姐妹称谓论文的补充分析与修订

> 本文件自成体系。请先通读，再阅读仓库代码，最后按第 2 节的顺序推进。标注【决策点】的位置必须停下来向用户汇报，等待确认后再继续。
> 论文全文（中文 PDF）若随任务一并提供，请以其中的定义为准；本文件与论文冲突时，先报告冲突，不要自行裁决。

0. 背景与目标

论文：《合取偏好与条件区分：兄弟姐妹称谓跨语言结构的关系解释》。数据来自 Kinbank，939 个八类齐全的记录系统，125 个谱系组，26,292 个无序类别对。公开仓库：`github.com/WuYusen825/kinship-semantic-interactions` 。

现有做法：单语言层面检验合取性与三项位置不对称；跨语言层面用逻辑回归（M0–M4）预测 28 个类别对的词形共享，并用谱系组留出、地域留出评估。

要解决的问题与对应任务

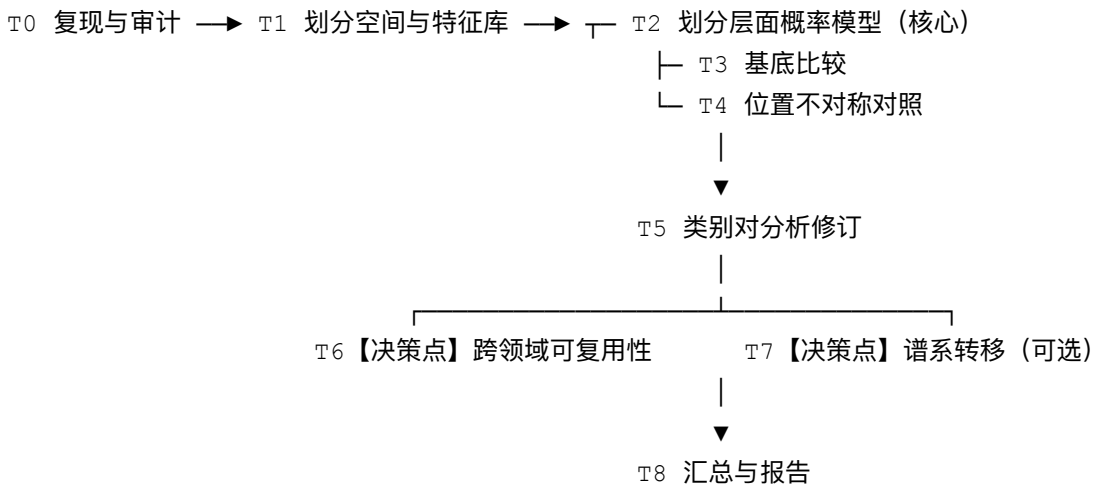
问题	对应任务
逻辑回归把同一划分内相互约束的 28 个类别对当作独立观测，总体交互无法区分"系统内条件组织"与"系统类型混合"	T2 划分层面概率模型
相对性别 q 是为了让划分更合取而选的基底，存在循环嫌疑	T3 基底比较
位置不对称（男性侧 vs 同性侧）的两种解释未做正面对照，而讨论部分提出的预测现有数据即可检验	T4 位置不对称对照
地域留出时复杂模型比 M0 更差，原因未拆分（基准率 vs 模式）；类别对依赖性处理粗糙；规格组合多而未汇总	T5 类别对分析修订
"关系表征可复用""历史路径"只停留在讨论	T6、T7（有决策点，可选）

总体目标：把论文从"回归拟合加未检验的解释框架"升级为"在划分层面建模，使竞争解释在同一模型里分出胜负"。

1. 总则

1. **先复现，后新增。** T0 通不过，不得开始其他任务。
2. **不改动既有定义。** 合取性、层级方向、"predicted/reverse"判定、折分配、权重方案一律沿用仓库现有实现。需要新定义时，另写函数并命名区分。
3. **先写计划，再跑分析。** 开始 T2–T7 前，把假设、定义、模型阶梯、评价指标写入 `docs/analysis_plan.md` 并提交。之后的结果标注为"预先设定"。分析计划之外的分析一律标注为"探索性"。（作者此前已见过探索结果，所以不要使用"验证性"一词。）
4. **记录全部尝试。** 每次运行把规格与主要指标追加到 `results/run_log.csv`（时间戳、任务、规格、指标、git commit）。
5. **阴性结果照常输出**，不得筛选。
6. **随机性固定。** 全局 `SEED = 20261016`，bootstrap 5000 次，按谱系组整组重抽。
7. **评估单位。** 主验证沿用谱系组整组五折；另做留一宏观区域、语言五折。训练与评分按谱系组等权；语言等权为敏感性分析。
8. **不用未收敛的模型做推断。** 收敛失败的拟合只记录在日志中。
9. **工程要求。** 一条命令复现全部结果（Makefile 或等价脚本）；关键函数有单元测试；大文件不入库；依赖写入环境文件。
10. 先读仓库现有结构，**沿用其目录与命名**，下文路径仅为建议。

2. 执行顺序



T2、T3、T4 可并行。T6、T7 在完成可行性报告后停下等待用户确认。

3. 记号

- 八类关系 = 参照者性别 `s` × 相对年龄 `a`（所指者相对参照者年长或年幼）× 所指者性别 `r`。相对性别 `q = s XOR r`。
- 先在 `docs/cell_coding.md` 写清仓库中八个单元的编号与 (s, a, r) 的对应，之后所有任务共

用这一张表。

- 28 个无序类别对 = C(8,2)；七种差异组合 = (Dr, Da, De) 的七个非零取值。
- "划分" = 对八个单元的集合划分，共 Bell(8) = **4140** 个。用 restricted growth string 作为规范表示。
- 严格划分样本 = 每类仅含单一词形的 625 个系统（108 个谱系组）。

T0 复现与审计

目的：确认仓库能复现论文数字，建立冻结基线。

步骤

1. 阅读仓库，输出 `docs/repo_map.md`（数据流、入口脚本、关键函数）。
2. 复现下列数字，计数类须完全一致，对数损失类容差 1e-4，bootstrap 区间容差 2e-3：
   - 样本规模：939 系统 / 125 谱系组 / 26,292 类别对；严格划分样本 625 系统 / 108 谱系组。
   - 非合取系统：四特征 22（3.5%，谱系等权 2.8%）；仅用 s、a、r 为 163；扩展六特征 21。
   - 表 2：年长侧性别区分 51/6（系统）、21/3（谱系）；男性侧年龄区分 17/5、11/3；同性侧年龄区分 81/1、17/1。
   - 表 3（谱系留出，939 系统）：M0 0.5088，M1 0.5020，M2 0.4961，M3 0.4944，M4 0.4943。（地域留出，909 系统）：0.5326，0.5410，0.5400，0.5407，0.5405。
   - 表 4：DrE −0.4578，DaB −0.1195，DaS −0.6558。
3. 有任何不一致，**停下来报告**，不要自行"修正"。
4. 通过后打 tag `baseline-v1`，把中间结果存入 `results/baseline/`。

验收：`results/baseline/reproduction_report.md` 列出每个数字的论文值、复现值、差值。

T1 划分空间与特征库

目的：为 T2–T4 提供共用基础设施。

实现

1. 枚举 4140 个划分，建表 `partitions.parquet`（RGS、类别数 k、各单元集合）。
2. **语言（language of description）**：用一组二值特征描述单元集合。实现下列语言，并给出"某集合在该语言下能否表示为单个合取式"的判定，以及最小描述长度：
   - `L_abs` = {s, a, r}

- `L_rel` = {q, a, r}，另做 {q, a, s} 作对照（二者是不同的坐标系，结果应同时报告）
- `L_all` = {s, a, r, q}
- 描述长度 DL：对单元集合求最小 DNF 的文字数（八个单元、至多四个特征，可穷举或 Quine–McCluskey）。划分的 DL = 各单元 DL 之和。
- 语言附带特征成本 λ：`DL_total = DL + λ · （语言特征数）`，λ ∈ {0, 1, 2, 3} 作扫描。

3. **位置特征**：对每个划分计算 P2、P3、P4 ∈ {+1（符合预测）, 0（不适用）, –1（相反）}，**直接调用仓库中既有的判定函数**，不要重写定义。
4. 把论文的 625 个系统映射到各自的划分编号，输出 `systems_to_partition.csv`。

单元测试（必须通过）

- 划分总数为 4140；每个划分是合法划分。
- 仅按 r 分为两类的划分在 `L_abs` 下合取。
- "同性 vs 异性"（{MM, FF} 与 {MF, FM}，不分年龄）在 `L_abs` 下**非**合取，在 `L_rel` 下合取。
- 在 `L_all` 下非合取的系统数 = 22；在 `L_abs` 下 = 163（与 T0 一致）。

T2 划分层面概率模型（核心）

目的：在划分层面建立统一模型，使合取偏好、基底选择、位置不对称与总体共享率出现在同一框架，并通过留出似然比较理论。

模型：对 4140 个划分定义条件 logit（最大熵）分布

`P(π) = exp(θ·φ(π)) / Z`， `Z = Σ_{π'} exp(θ·φ(π'))`（对全部 4140 个划分精确求和）

极大似然估计为凸问题，用 L-BFGS。

模型阶梯（特征 φ）

编号	特征	含义
A0	无（均匀分布）	下界
A1	k, k²	类别数，允许内部最优
A2	A1 + conj_abs	全部单元在 `L_abs` 下合取
A3	A1 + conj_rel	全部单元在 `L_rel` 下合取
A4	A1 + DL_abs	描述长度（绝对基底）

A5	A1 + DL_rel	描述长度（相对基底）
A6	A1 + DL_all(λ)	四特征语言，λ 扫描
A7	A2–A6 中表现最好者 + P2, P3, P4	加入位置特征
A8	A7 + 同类别数下的重要交互（仅在计划中预先列出者）	可选

评估

- 谱系组整组五折（沿用既有折分配）、留一宏观区域；指标为留出的每系统平均对数似然（nats），与 A0、A1 相比的差值。
- 区间：谱系组整组 bootstrap（固定折外预测重抽 5000 次）。
- 正则化：对 θ 加 L2，强度在内层谱系分组交叉验证中从 {0, 0.01, 0.1, 1} 选择；同时报告固定强度下的敏感性。
- 权重：谱系组等权为主，语言等权与无权为敏感性。

样本：主分析用严格划分样本（625）。敏感性分析：

- (b) 全部 939 系统，划分取"词形集合完全相同"的等价类（该定义下每个系统都是合法划分）；
- (c) 全部 939 系统，划分取共享图的连通分量。

导出预测与后验预测检查

1. 由拟合分布导出 28 个类别对的共享概率，再汇总为七种差异组合，与实测画对照图（对应论文图 1）。
2. 在严格划分样本上，用相同折重新拟合 M0–M4，比较"划分模型导出的类别对对数损失"与 M0–M4 的类别对对数损失。
3. 从拟合分布采样生成合成数据，检查类别数分布、合取比例、P2–P4 的符合/相反比例是否与实测一致。
4. **混合假设检验**：划分模型没有显式交互项，检查它导出的共享率是否已经呈现论文中 M2 的非加性；报告导出的 logit 对照与 M2 交互系数的对应。

需要回答的问题（写入结果摘要）

- Q1：相对基底（A3/A5）是否比绝对基底（A2/A4）提高留出似然？差值区间是否排除零？
- Q2：位置特征（A7）是否在最佳基底之上带来增量？三个特征各自的系数符号与区间？
- Q3：划分模型导出的类别对预测是否不劣于 M2/M4？
- Q4：总体非加性是否可由划分类型分布单独复现？

输出：`results/t2/`（模型阶梯表、系数表、留出似然表、图）。

T3 基底比较（处理 q 的循环问题）

目的：说明选 q 不是为了凑合取结果，而是在候选特征中具有可检验的优势。

3a 穷举候选第四特征

- 候选 = 对八个单元的全部二分，共 $2^7 - 1 = 127$ 个。
- 对每个候选 f，语言 `L_f = {s, a, r, f}`：
  - `C_f` = 4140 个划分中全部单元合取的个数（纯组合量，与数据无关）；
  - `N_f` = 625 个严格划分系统中全部单元合取的个数（系统与谱系组两种口径）；
  - 富集度 `E_f = (N_f/625) / (C_f/4140)`。
- 另外用论文既有的随机参照（保持词项数与类别大小）计算 `N_f` 的参照分布，报告 `N_f` 的参照区间。
- 检查：`N_q` 应为 625 – 22 = 603。
- 输出：127 个特征的表；散点图（横轴 `C_f/4140`，纵轴 `N_f/625`，标注 q、a、r、s 与富集度最高的若干特征）；q 的排名。

3b 对称性分类

- 全局性别互换 (s, r) → (¬s, ¬r) 把八个单元分成四个轨道。在该变换下不变的二分应只有 7 个（请核对）。
- 报告 q 与这 7 个特征中其余者的 `C_f`、`N_f`、`E_f`。该结果用于论证"q 是少数在性别互换下不变的关系特征之一"。

3c 带成本比较

- 用 T1 的 DL 与 λ，比较三种基底下全体系统的平均描述长度，并报告 λ 的取值范围内排序是否稳定。

验收：`results/t3/` 含上述表图；`N_q = 603` 检查通过。

T4 位置不对称的正面对照

目的：用现有数据检验两种解释，即标记性解释（年龄区分偏男性侧）与关系排序解释（年龄区分偏同性配置，且男男、女女相当）。

定义（参照者、所指者性别记为 (ego, referent)，配置 $c \in \{MM, MF, FM, FF\}$）

- 年龄区分集合 `A(sys)`：在配置 c 下，"年长"与"年幼"所指者属于不同类别（仅严格划分样本）。
- 性别区分集合 `G(sys)`：在 (ego 性别, 年龄) 的四种配置下，男性所指者与女性所指者属于不同类别。

- 偏性（partial）系统：`0 < |A| < 4`（年龄）或 `0 < |G| < 4`（性别）。
- 谱系口径沿用论文：谱系内取多数类型，平局单列，不进入检验分母。

检验与预测表（对偏性年龄系统）

对照	标记性解释预测	关系排序解释预测
(i) 仅同性配置 {MM, FF} 的子集 vs 仅异性配置 {MF, FM} 的子集	无特定预测	同性多于异性
(ii) 仅同性的系统内，A = {MM} vs A = {FF}	男男多于女女	二者相当
(iii) 仅异性的系统内，A = {FM}（男性所指者）vs A = {MF}（女性所指者）	男性所指者多	无偏好
(iv) 男性所指者配置 {MM, FM} vs 女性所指者配置 {MF, FF}	男性侧多	无偏好（由同性配置间接产生）

- (ii) 是最有判别力的对照。对相当性用等价性检验：比例差的谱系整组 bootstrap 区间需落入预先设定的等价边界（建议 ±0.15，写入分析计划后不得改）。
- 性别区分部分（D2）：年长侧集中是否在男性参照者与女性参照者中都成立（分别报告），避免把参照者性别混入结论。
- 各检验使用精确二项或 mid-p，对预先列出的对照作 Holm 校正。
- 稳健性：分别排除南岛、帕马–恩永甘；分宏观区域报告方向。

输出：`results/t4/` 含系统级与谱系级计数表（含 A 的 14 种类型频数）、对照结果表、图（对应论文图 2 的扩展）。

T5 类别对分析修订

5a 地域留出的拆分

- 对每个留出区域计算三种得分：①原始（既有）；②截距重校准（模型系数固定，仅在留出区域上重估一个截距偏移）；③AUC（按谱系等权，区域宏平均）。
- 输出每个区域的实测共享基准率与模型平均预测率，作校准图（对应论文图 1 的区域面板）。
- 解释规则：②③中若 M2/M4 优于 M0 而①不然，则结论应表述为"结构可迁移，基准率有区域差异"，并如实报告。

5b 依赖结构

- 对 M0–M4 用谱系组聚类稳健协方差（statsmodels GLM 的 cluster 选项或等价实现），与既有谱系重拟合区间并列。
- 仅含谱系随机截距的混合模型（R `lme4::glmer` 或可用的等价实现），记录收敛状态；只在收敛时纳入主表。
- 不尝试复现论文中未收敛的"语系×区域交叉随机截距"模型。

5c 规格曲线

- 因子：共享定义（五种）× 估计方法（无惩罚+Firth / C=1 岭）× 权重（谱系组等权 / 语言等权）× 验证目标（谱系五折 / 留一区域 / 语言五折）。
- 对每个规格报告 M2–M0、M4–M2、M4–M0 的增益与整组 bootstrap 区间，按增益排序作图，标出论文的主规格。
- 表格列出全部组合的结果。

5d 严格样本重拟合

- 在 625 系统上用与 T2 相同的折重新拟合 M0–M4，供 T2 的类别对比较使用。

T6【决策点】跨领域可复用性

目的：检验"相对性别作为可复用的关系表征"是否在兄弟姐妹之外也成立。

第一步（可行性与定义，不跑结果分析）

1. 检查 Kinbank 的亲属类型编码，列出含参照者性别与所指者性别变异的非兄弟姐妹领域（如堂表亲、父母辈的兄弟姐妹等，以实际数据为准）。
2. 在 `docs/t6_operationalization.md` 中提出至少两种"相对性别使用度"的定义，并给出兄弟姐妹领域的对应指标，候选包括：①该系统兄弟姐妹划分在 `L_abs` 下是否非合取；②连续指标 `DL_abs − DL_rel`。
3. 指定混淆控制：两个领域各自的类别数（避免"区分越多越相关"的平凡结果）、谱系。
4. **停止，向用户汇报并等待确认。**

第二步（用户确认后）：谱系聚类稳健的逻辑回归，并在谱系内置换检验，输出效应量与区间；标注为探索性。

T7【决策点】谱系转移（可选）

第一步（只做可行性报告）

1. 确认可用的系统发育信息：仅 Glottolog 拓扑，还是有带分支长度的树（如南岛语系）。
2. 若只有拓扑，列出可行的近似（单位分支长度、Grafen 等）与敏感性设计。
3. 给出状态空间的粗化方案（≤ 6 个状态，如"合取/非合取"与类别数分层）。

4. **停止，向用户汇报并等待确认。**

第二步（用户确认后）：拟合 Mk 模型，比较等速率、全异速率与"转入非合取的速率"受限模型（AIC），先在有可靠树的语系上做，再谨慎汇总。标注为探索性。

T8 汇总与报告

1. `results/summary.json`：论文将引用的全部数字，附产生它的脚本与函数。
2. `results/report.md`：每个任务的方法、结果、图表、与论文原结果的差异。
3. 图表命名与论文图表编号对应，新增图表用 `Fx_` 前缀。
4. `CHANGELOG.md`：记录新增与未改动的部分。

4. 建议的目录结构（以仓库现状为准）

```
docs/      analysis_plan.md  repo_map.md  cell_coding.md  t6_operationalization.m
src/       partitions.py  languages.py  partition_model.py  basis_enrichment.py
           position_tests.py  pair_models.py  spec_curve.py
tests/     test_partitions.py  test_languages.py  test_partition_model.py
results/   baseline/  t2/  t3/  t4/  t5/  t6/  t7/  summary.json  run_log.csv
```

5. 通用验收标准

- 所有单元测试通过；T0 的复现报告无未解释差异。
- 概率模型的 `Σ P(π) = 1`（数值误差 1e-9 内）。
- 每个数字可追溯到脚本；`make all` 在干净环境中可复现。
- 分析计划在运行前提交，运行记录完整。

6. 禁止事项

- 不得在未告知用户的情况下修改论文既有定义、折分配或权重。
- 不得因结果不理想而更换指标、删除规格或缩小样本。
- 不得把探索性结果标注为验证性。
- 不得使用未收敛模型的估计做推断。
- 不得在 T6、T7 的决策点之前运行结果分析。

7. 结果与论文的对应（供后续改稿）

结果	在论文中的角色
T2 的 Q1、Q2	主结果：关系基底与位置特征的留出似然证据
T3	回应 q 的循环嫌疑，作为合取结论的支撑
T4	主结果：标记性解释与关系排序解释的正面对照
T5	修订原有预测结论，限定跨地域结论的含义
T6、T7	若完成，作为补充证据支持可复用性与历史路径；否则保留为展望

8. 需要用户确认的事项

1. 仓库的本地路径、Python/R 运行环境、Kinbank 与 Glottolog 的版本是否已固定。
2. 是否允许新增依赖。
3. T6 的操作化定义（决策点）。
4. T7 的树与近似方案（决策点）。
5. T4 的等价边界（默认 ±0.15）。